



UNIVERSITÉ
CAEN
NORMANDIE

UFR DES SCIENCES



Normandie Université



IGL master

TRAITEMENT ET ANALYSE SPECTRALE D'UN SIGNAL AUDIONUMÉRIQUE

Présenté par :

Rayan ROWER



23 / 02 / 2026

Dans le cadre de ce projet de traitement du signal numérique, j'ai choisi d'analyser un enregistrement audio issu d'un culte dominical, enregistré le 1er février 2025 à l'Église Protestante Unie de Caen. Cet enregistrement capture une séquence musicale collective, incluant un chant interprété par l'assemblée et accompagné par plusieurs instruments. Ce contexte présente un intérêt particulier pour le traitement du signal, car il combine une diversité de sources sonores dans un environnement acoustique complexe.

1 Contexte et nature du signal

Les cultes dans cette église impliquent généralement une instrumentation variée, visant à enrichir l'expression musicale. Lors de cet enregistrement, les musiciens utilisaient :

- Trois pianos,
- Une guitare classique et une guitare basse,
- Une flûte traversière,
- Un violoncelle.

L'enregistrement capture non seulement les instruments, mais aussi :

- Les voix des fidèles, dont les contributions vocales varient en intensité et en justesse,
- Les applaudissements ponctuels,
- Les bruits ambiants liés à l'acoustique de l'église (réverbérations, mouvements d'air, etc.),
- Les artefacts introduits par le matériel d'enregistrement, non professionnel.

Ce signal est donc multicomposant, mêlant des sources harmoniques (instruments), des transitoires (applaudissements), et des bruits parasites. Son analyse permet d'illustrer les défis du traitement du signal en milieu réel, où les sources ne sont ni isolées ni stationnaires.

L'objectif principal de ce projet est :

- Classer les composantes fréquentielles du signal en identifiant les contributions spécifiques de chaque instrument (et des voix), malgré la présence de bruits.
- Reconstruire le signal initial après extraction des informations pertinentes, en utilisant la Transformée de Fourier Inverse, afin de valider la fidélité du processus.

2 Méthodes

L'enregistrement initial, sauvegardé sous le format .aac (nommé `exulte_culte.aac`), a été converti en fichier .wav (format ASCII compatible avec les bibliothèques Python) à l'aide de la bibliothèque `librosa`¹. Ce prétraitement est essentiel pour faciliter les analyses ultérieures.

Pour les calculs et les visualisations, j'ai principalement utilisé :

- **SciPy**² : Pour appliquer la Transformée de Fourier (TF) et la Transformée de Fourier Inverse (TFI), outils centraux pour la décomposition et la reconstruction du signal.
- **Matplotlib** : Pour représenter graphiquement les spectres de fréquence et les signaux temporels.

1. <https://github.com/librosa/librosa>, 23 février 2026

2. <https://docs.scipy.org/doc/scipy/tutorial/>, 23 février 2026

- **IPython.display**³ : Pour écouter les extraits audio à chaque étape de classification, permettant une validation auditive des résultats.




FIGURE 1 – Flux de Traitement pour l'Analyse et la Reconstitution des Signaux Audio

3. <https://ipython.readthedocs.io/en/stable/api/generated/IPython.display.html>, 23 février 2026

3 Analyses des résultats

3.1 Importation du signal audio




FIGURE 2 – Signal audio du culte

Le signal temporel (*cf.* figure 2) montre une évolution de l'amplitude sur environ 93 secondes, avec des variations marquées reflétant les dynamiques du culte. On observe des pics d'amplitude réguliers, correspondant aux moments de chant ou d'instruments joués, suivis d'une diminution progressive vers la fin de l'enregistrement. Ces fluctuations rapides superposées au signal principal révèlent la présence de bruits ambiants, comme les applaudissements ou les mouvements dans l'église, ainsi que les artefacts liés à l'enregistrement.

Le spectrogramme de la figure 3 illustre la répartition des fréquences en fonction du temps, avec des bandes horizontales distinctes. Entre 100 Hz et 500 Hz, on note une dominance des instruments graves comme le violoncelle ou le piano. Les fréquences comprises entre 1 kHz et 4 kHz révèlent la présence des voix et des instruments plus aigus, tels que la flûte ou la guitare classique. Les motifs répétitifs et les zones jaunes ou vertes indiquent les moments les plus intenses, comme les chœurs ou les climaxes du morceau. Les zones bleues ou violacées montrent un bruit de fond présent, mais qui ne masque pas les fréquences dominantes.




FIGURE 3 – Spectrogramme du signal audio

Le spectre de fréquence (*cf.* figure 4 et figure 5) de l'enregistrement révèle une répartition caractéristique des instruments et des voix présents lors du culte.

Les basses fréquences (20–250 Hz) sont dominées par les instruments graves, tels que :

- Le violoncelle, dont la plage fondamentale s'étend généralement de 65 Hz à 1 kHz, avec une prédominance dans les 80–500 Hz.
- Les pianos, qui couvrent une large gamme allant de 27 Hz (note la plus grave) à 4,186 Hz (note la plus aiguë), mais dont les harmoniques fondamentales des notes jouées dans ce contexte se situent souvent entre 50 Hz et 1 kHz.

Ces pics prononcés dans cette plage indiquent des notes bien définies, typiques de ces instruments, avec des harmoniques riches qui contribuent à la texture sonore globale.




FIGURE 4 – Spectre de fréquence du signal audio




FIGURE 5 – Spectre de fréquence du signal audio pour $0 < f < 2000$

Les fréquences moyennes (250–2000 Hz) correspondent principalement :

- Aux voix humaines, qui se situent généralement entre 300 Hz et 3 kHz, avec une concentration d'énergie autour de 1 kHz, cohérente avec les fréquences formantes des voyelles.
- À la guitare classique, dont les fréquences fondamentales s'étendent de 82 Hz (Mi grave) à 1 kHz, avec des harmoniques pouvant atteindre 4 kHz.

- À la flûte, dont les fréquences fondamentales se situent entre 262 Hz (Do4) et 2 kHz, bien que son énergie soit atténuée dans cet enregistrement.

Les hautes fréquences (au-delà de 2 kHz) montrent une énergie très limitée, ce qui suggère que les composantes aiguës des instruments, comme les harmoniques élevées de la flûte ou de la guitare, sont soit peu présentes, soit atténuées par l'acoustique de l'église ou les limitations du matériel d'enregistrement. En ce qui concerne les bruits indésirables, plusieurs sources peuvent être identifiées et ciblées pour une élimination ou une réduction :

Les bruits de fond (vent, mouvements dans l'église) se manifestent généralement sous forme de bruit blanc, plus perceptible dans les hautes fréquences (au-delà de 4 kHz). Ces bruits peuvent être atténués par un filtrage passe-bas. Les applaudissements et les bruits impulsifs (chocs, déplacements) apparaissent comme des pics soudains et larges dans le spectre, souvent dans les fréquences moyennes à hautes (1 kHz–8 kHz). Ces éléments peuvent être réduits par un filtrage adaptatif ou une détection de transitoires.


Les artefacts électroniques (bruit du matériel d'enregistrement) se manifestent souvent par des fréquences parasites ou un fond continu dans les très hautes fréquences (au-delà de 10 kHz). Ces artefacts peuvent être minimisés par un filtrage passe-bas ou un nettoyage numérique.




3.2 Classification




Les spectres de fréquence montrent des pics distincts pour chaque instrument et type de voix, mais les spectres des voix et de la flûte semblent moins définis et plus compressés.


Les spectres des voix présentent des composantes fréquentielles étroites et rapprochées. Cela rend difficile la distinction claire des harmoniques et des formants, suggérant un besoin de meilleure résolution fréquentielle.

Le spectre de la flûte montre des pics, mais ils apparaissent moins nets et moins bien séparés, indiquant une difficulté à distinguer les détails fins des harmoniques. Tandis que, le piano, la guitare classique et la guitare basse montrent des pics plus nets et bien définis, indiquant une bonne séparation des composantes fréquentielles.













Pour les voix et la flûte, où les détails spectraux sont moins visibles, l'utilisation du zero padding peut améliorer la résolution fréquentielle. Cela permet de mieux visualiser et analyser les composantes fréquentielles, rendant les pics plus distincts et facilitant l'identification des harmoniques.

3.3 Amélioration de la Résolution Fréquentielle par Zero Padding

Dans le cadre de notre analyse spectrale, nous avons appliqué la technique du zero padding pour améliorer la résolution fréquentielle des signaux associés aux voix (homme adulte, femme adulte, enfants) et à la flûte. Cette méthode, qui consiste à ajouter des zéros à la fin du signal dans le domaine temporel ou fréquentiel, permet d'obtenir une représentation plus fine du spectre de fréquence sans modifier le contenu informatif du signal.

Les figures suivantes illustrent les spectres de fréquence des signaux après application du zero padding. Cette approche est particulièrement utile pour les signaux dont les composantes fréquentielles sont proches ou peu intenses, comme c'est souvent le cas pour les voix et certains instruments à vent. Les résultats obtenus permettent de mieux visualiser les détails des spectres et d'affiner l'analyse des harmoniques.





Après l'application du zero padding, les spectres de fréquence des voix et de la flûte révèlent des améliorations notables en termes de résolution et de clarté. Tout d'abord, pour les voix masculines adultes, les pics de fréquence deviennent mieux définis, en particulier entre 0 et 100 Hz, ce qui permet une meilleure visualisation des harmoniques et des formants caractéristiques. De même, les voix féminines adultes montrent des composantes fréquentielles plus distinctes,


avec des pics bien marqués entre 50 et 150 Hz, facilitant ainsi l'identification des détails des fréquences plus élevées. En ce qui concerne les voix d'enfants, les pics de fréquence apparaissent plus nets et mieux répartis sur une plage plus large allant jusqu'à 200 Hz, ce qui met en évidence une meilleure résolution des harmoniques, souvent plus variées chez les enfants.

Pour la flûte, les pics de fréquence deviennent plus distincts et mieux séparés, notamment dans les basses et moyennes fréquences. Ainsi, le zero padding a permis de mieux visualiser les subtilités du son de cet instrument, qui étaient moins évidentes auparavant. En somme, cette technique améliore significativement la résolution des spectres de fréquence, rendant les pics plus nets et mieux définis, ce qui facilite l'analyse des composantes fréquentielles des signaux audio, en particulier pour les sons complexes comme les voix et les instruments à vent.

3.4 Reconstitution et comparaison des Signaux

Après avoir isolé et amélioré les composantes fréquentielles des différents instruments et voix grâce au filtrage et au zero padding, nous procédons à la reconstitution du signal global. Cette étape consiste à combiner les signaux filtrés de chaque instrument et voix pour obtenir un signal reconstruit, qui devrait être proche de l'enregistrement original.

L'objectif est de vérifier la qualité de cette reconstitution en comparant le signal reconstruit au signal original, tant dans le domaine temporel que dans le domaine fréquentiel. Cette analyse permet d'évaluer l'efficacité de notre méthode de classification et de filtrage, ainsi que l'impact des traitements appliqués sur la fidélité du signal final.



Les résultats obtenus pour la reconstitution des signaux et des spectres montrent une comparaison visuelle et quantitative intéressante. Sur les graphiques, on observe que le signal temporel

reconstruit suit de près le signal original, bien que des écarts mineurs soient visibles, notamment dans les détails fins de l'amplitude. Cela suggère que la reconstitution a globalement préservé la structure temporelle du signal, malgré quelques imperfections.

En ce qui concerne les spectres de fréquence, le spectre reconstruit épouse bien les contours du spectre original, avec des pics principaux qui se superposent de manière satisfaisante. Cependant, on note quelques différences dans les amplitudes des composantes fréquentielles, ce qui peut indiquer une légère perte de précision dans certaines plages de fréquences.

Les métriques quantitatives confirment ces observations. L'erreur quadratique moyenne (MSE) de 0.0172 indique une faible différence globale entre le signal original et le signal reconstruit, ce qui est encourageant. Le rapport signal sur bruit (SNR) de -0.25 dB suggère que le bruit introduit par la reconstitution est relativement faible, bien qu'il y ait une légère dégradation de la qualité. Les valeurs d'erreur spectrale (34.47) et de distance spectrale (34.44) montrent des écarts dans les amplitudes spectrales, ce qui est cohérent avec les différences visibles sur le graphique des spectres.

Le score STOI de 0.9939 est particulièrement élevé, indiquant une excellente intelligibilité du signal reconstruit par rapport à l'original, ce qui est crucial pour les applications impliquant la parole ou la musique. Enfin, le SI-SDR de 19.33 dB confirme que la distorsion globale est faible et que le signal reconstruit est de bonne qualité.

Ces résultats montrent que la méthode de reconstitution utilisée est efficace, préservant la majorité des caractéristiques temporelles et spectrales du signal original. Les écarts observés peuvent être attribués aux limites des techniques de filtrage et de reconstitution, mais restent dans une marge acceptable pour une analyse de ce type.

4 Conclusion

Les analyses menées sur la reconstitution des signaux audio montrent des résultats globalement satisfaisants. Grâce aux techniques de filtrage et de zero padding appliquées, nous avons réussi à isoler et reconstituer les composantes fréquentielles des différents instruments et voix. Les comparaisons entre les signaux originaux et reconstitués, tant dans le domaine temporel que spectral, révèlent une bonne préservation des caractéristiques principales.

Les métriques quantitatives, comme le MSE de 0.0172, le STOI de 0.9939, et le SI-SDR de 19.33 dB, confirment que la qualité de la reconstitution est élevée, avec une intelligibilité et une fidélité satisfaisantes. Malgré quelques écarts mineurs, notamment dans les amplitudes spectrales, les résultats obtenus sont cohérents et prometteurs.

Pour améliorer encore la qualité de la reconstitution, il serait intéressant d'explorer des méthodes de filtrage plus avancées, comme l'analyse en composantes indépendantes (ICA) ou les réseaux de neurones pour la séparation de sources. De plus, affiner les plages de fréquences pour chaque instrument et voix pourrait réduire davantage les écarts observés. Cette étude a permis de valider l'efficacité des techniques utilisées pour la reconstitution des signaux audio, ouvrant la voie à des applications pratiques dans le domaine du traitement du signal.